

UJIAN AKHIR SEMESTER

**ANALISIS SEGMENTASI PELANGGAN MALL MENGGUNAKAN
METODE AGGLOMERATIVE HIERARCHICAL CLUSTERING
BERDASARKAN ANNUAL INCOME DAN SPENDING SCORE UNTUK
MENDUKUNG STRATEGI PEMASARAN**



Oleh:

**REFA AULIA
24250006**

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK DAN ILMU KOMPUTER
UNIVERSITAS NAHDLATUL ULAMA INDONESIA
JAKARTA
2026**

UJIAN AKHIR SEMESTER

**ANALISIS SEGMENTASI PELANGGAN MALL MENGGUNAKAN
METODE AGGLOMERATIVE HIERARCHICAL CLUSTERING
BERDASARKAN ANNUAL INCOME DAN SPENDING SCORE UNTUK
MENDUKUNG STRATEGI PEMASARAN**

UJIAN AKHIR SEMESTER

Diajukan sebagai salah satu syarat untuk memenuhi
ujian akhir semester

Oleh:

**REFA AULIA
24260005**

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK DAN ILMU KOMPUTER
UNIVERSITAS NAHDLATUL ULAMA INDONESIA
JAKARTA
2026**

KATA PENGANTAR

Puji syukur kehadiran Allah SWT atas segala rahmat, hidayah, dan karunia-Nya sehingga penulis dapat menyelesaikan Laporan Ujian Akhir Semester (UAS) yang berjudul "ANALISIS SEGMENTASI PELANGGAN MALL MENGGUNAKAN METODE AGGLOMERATIVE HIERARCHICAL CLUSTERING BERDASARKAN ANNUAL INCOME DAN SPENDING SCORE UNTUK MENDUKUNG STRATEGI PEMASARAN" dengan baik dan tepat waktu.

Laporan ini disusun untuk memenuhi salah satu tugas Ujian Akhir Semester (UAS). Dalam penyusunannya, penulis berusaha menyajikan pembahasan mengenai penerapan metode Agglomerative Hierarchical Clustering dalam melakukan segmentasi pelanggan berdasarkan Annual Income dan Spending Score. Melalui analisis ini diharapkan dapat diperoleh kelompok-kelompok pelanggan yang memiliki karakteristik serupa sehingga dapat menjadi dasar dalam penyusunan strategi pemasaran yang lebih efektif dan tepat sasaran.

Penulis menyadari bahwa dalam penyusunan laporan ini masih terdapat berbagai kekurangan, baik dari segi penyajian maupun isi materi. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang membangun dari berbagai pihak demi penyempurnaan laporan ini di masa yang akan datang.

Dalam penyusunan laporan ini, penulis memperoleh bantuan, dukungan, serta bimbingan dari berbagai pihak. Oleh karena itu, penulis menyampaikan ucapan terima kasih kepada:

Allah SWT yang telah memberikan kesehatan, kekuatan, dan kemudahan sehingga laporan ini dapat diselesaikan.

Bapak/Ibu Dosen pengampu mata kuliah yang telah memberikan ilmu, arahan, dan bimbingan selama proses perkuliahan.

Kedua orang tua dan keluarga yang senantiasa memberikan doa, motivasi, serta dukungan kepada penulis.

Teman-teman yang telah memberikan bantuan, masukan, dan semangat selama penyusunan laporan.

Semua pihak yang telah membantu, baik secara langsung maupun tidak langsung, sehingga laporan ini dapat terselesaikan.

Penulis berharap laporan Ujian Akhir Semester (UAS) ini dapat memberikan manfaat serta menambah wawasan bagi pembaca mengenai penerapan metode Agglomerative

Hierarchical Clustering dalam segmentasi pelanggan. Semoga laporan ini juga dapat menjadi salah satu referensi bagi mahasiswa yang ingin mempelajari penerapan teknik clustering pada bidang data mining dan machine learning.

Bogor, 28 Juni 2026

Penulis

DAFTAR ISI

DAFTAR ISI	-----
KATA PENGANTAR	-----
DAFTAR ISI	-----
DAFTAR TABEL	-----
DAFTAR GAMBAR	-----
DAFTAR RUMUS	-----
BAB I PENDAHULUAN	-----
1.1 Latar Belakang	-----
1.2 Rumusan Masalah	-----
1.3 Batasan Masalah	-----
1.4 Tujuan Penelitian	-----
1.5 Manfaat Penelitian	-----
• Manfaat Teoritis	-----
• Manfaat Praktis	-----
1.6 Metode Penelitian	-----
• Metode Pengumpulan Data	-----
• Metode Analisis Data	-----
• Metode Pemodelan Data	-----
• Metode Evaluasi Model	-----
1.7 Sistematika Penulisan	-----
BAB II TINJAUAN PUSTAKA	-----
2.1 Penelitian Terdahulu	-----
2.2 Landasan Teori	-----
2.2.1 Data Mining	-----
2.2.2 Machine Learning	-----
2.2.3 Unsupervised Learning	-----
2.2.4 Clustering	-----
2.2.5 Customer Segmentation	-----
2.2.6 Hierarchical Clustering	-----
• Pengertian Hierarchical Clustering	-----
• Jenis Hierarchical Clustering	-----
• Agglomerative Clustering	-----
• Divisive Clustering	-----
• Cara Kerja Hierarchical Clustering	-----

• Kelebihan dan Kekurangan Hierarchical Clustering-----	
BAB III METODOLOGI PENELITIAN-----	
3.1 Kerangka Berpikir-----	
3.2 Pengumpulan dan Pengolahan Data -----	
3.2.1 Dataset Mall Customer Segmentation -----	
3.2.2 Deskripsi Dataset-----	
3.2.3 Pengumpulan Data -----	
3.2.4 Pengolahan Data-----	
• Import Dataset -----	
• Pemeriksaan Missing Value -----	
• Pemeriksaan Data Duplikat -----	
• Statistik Deskriptif -----	
• Visualisasi Data -----	
• Feature Selection -----	
• Data Scaling -----	
3.3 Perancangan Teknik/Model-----	
3.3.1 Flowchart Penelitian-----	
3.3.2 Tahapan Hierarchical Clustering -----	
• Menghitung Matriks Jarak -----	
• Membentuk Dendrogram-----	
• Menentukan Jumlah Cluster -----	
• Membangun Model Agglomerative Clustering -----	
• Visualisasi Cluster -----	
• Profiling Cluster-----	
3.4 Evaluasi Teknik/Model-----	
3.4.1 Silhouette Score -----	
3.4.2 Interpretasi Hasil Clustering -----	

BAB 1

PENDAHULUAN

Bab ini menjelaskan dasar dilakukannya penelitian ini, yang terdiri dari latar belakang, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, metode penelitian, dan sistematika penulisan.

1.1. Latar Belakang

Persaingan industri ritel yang semakin ketat menuntut setiap pelaku usaha, termasuk pengelola pusat perbelanjaan (mall), untuk memahami pelanggannya secara lebih mendalam agar dapat menyusun strategi pemasaran yang tepat sasaran. Memahami perilaku belanja pelanggan secara individual untuk setiap pelanggan tentu tidak efisien apabila jumlah pelanggan sangat besar, sehingga dibutuhkan suatu pendekatan yang dapat mengelompokkan pelanggan ke dalam beberapa segmen dengan karakteristik yang relatif homogen. Pendekatan inilah yang dikenal dengan istilah customer segmentation, yang menjadi salah satu komponen penting dalam customer relationship management (CRM) untuk membangun keunggulan kompetitif suatu bisnis (Rungruang, Riyapan, Intarasit, Chuarkham, & Muangprathub, 2023).

Salah satu pendekatan yang banyak digunakan dalam segmentasi pelanggan adalah teknik unsupervised learning berupa algoritma clustering, di antaranya K-Means Clustering dan Hierarchical (Agglomerative) Clustering. Berbeda dengan K-Means yang mengharuskan jumlah cluster ditentukan terlebih dahulu, Hierarchical Clustering membangun struktur pengelompokan secara bertingkat yang divisualisasikan melalui dendrogram, sehingga jumlah cluster yang optimal dapat ditentukan berdasarkan struktur data itu sendiri (Abdulhafedh, 2021). Beberapa penelitian bahkan menunjukkan bahwa Hierarchical Clustering dapat menghasilkan nilai Silhouette Score yang lebih baik dibandingkan K-Means pada data perilaku pelanggan, sehingga mampu mengidentifikasi segmen pelanggan secara lebih akurat.

Pada penelitian ini, segmentasi dilakukan pada dataset Mall Customer Segmentation Data yang merupakan dataset publik yang umum digunakan dalam studi pembelajaran mesin terkait perilaku pelanggan ritel. Dataset ini terdiri dari 200 data pelanggan dengan lima atribut, yaitu CustomerID, Gender, Age, Annual Income, dan Spending Score. Beberapa penelitian terdahulu yang menggunakan dataset sejenis menunjukkan bahwa atribut Annual Income dan Spending Score merupakan dua variabel utama yang paling

relevan digunakan dalam proses clustering, karena secara langsung menggambarkan kemampuan ekonomi sekaligus kecenderungan belanja pelanggan, sedangkan atribut Gender dan Age umumnya hanya digunakan sebagai informasi pendukung pada tahap analisis profil cluster.

Berdasarkan uraian tersebut, penelitian ini berupaya menerapkan metode Agglomerative Hierarchical Clustering untuk mengelompokkan pelanggan mall berdasarkan Annual Income dan Spending Score. Proses penelitian dilakukan melalui beberapa tahapan, yaitu eksplorasi dan visualisasi data awal, praproses data (feature selection dan scaling), pembuatan dendrogram untuk membantu menentukan jumlah cluster yang optimal, penerapan algoritma Agglomerative Clustering, visualisasi hasil clustering, hingga analisis dan profiling karakteristik setiap cluster yang terbentuk. Hasil pengelompokan ini diharapkan dapat memberikan gambaran segmen pelanggan yang lebih jelas, sehingga dapat dijadikan dasar pertimbangan dalam menyusun strategi pemasaran maupun layanan yang lebih tepat sasaran bagi pengelola mall.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut.

- 1) Bagaimana pola pengelompokan pelanggan mall dapat diidentifikasi berdasarkan atribut Annual Income dan Spending Score menggunakan metode Agglomerative Hierarchical Clustering?
- 2) Berapa jumlah cluster yang optimal yang dapat dibentuk dari dataset Mall Customer Segmentation berdasarkan hasil visualisasi dendrogram?
- 3) Bagaimana karakteristik (profil) masing-masing cluster pelanggan yang terbentuk, dan bagaimana hasil tersebut dapat dimanfaatkan sebagai dasar strategi pemasaran?

1.3. Batasan Masalah

Agar penelitian ini lebih terarah dan fokus, maka ditetapkan beberapa batasan masalah sebagai berikut.

Dataset yang digunakan adalah dataset publik Mall Customer Segmentation Data yang terdiri dari 200 data pelanggan dengan 5 atribut, yaitu CustomerID, Gender, Age, Annual Income, dan Spending Score.

Fitur yang digunakan dalam proses clustering dibatasi pada dua atribut numerik, yaitu Annual Income (k\$) dan Spending Score (1-100); atribut Gender dan Age tidak digunakan

dalam pembentukan cluster, namun dapat digunakan sebagai informasi tambahan pada tahap profiling.

Metode clustering yang digunakan adalah Agglomerative Hierarchical Clustering dengan bantuan visualisasi dendrogram, dan tidak membandingkan secara mendalam dengan algoritma clustering lain seperti K-Means atau DBSCAN.

Implementasi dilakukan menggunakan bahasa pemrograman Python pada lingkungan Jupyter Notebook, dengan bantuan library NumPy, Pandas, Matplotlib, Seaborn, dan Scikit-learn.

Penelitian ini bersifat deskriptif-eksploratif dan tidak sampai pada tahap implementasi model ke dalam sistem atau aplikasi produksi.

1.4. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah dijabarkan, tujuan dari penelitian ini adalah sebagai berikut.

- 1) Mengidentifikasi pola pengelompokan pelanggan mall berdasarkan Annual Income dan Spending Score menggunakan metode Agglomerative Hierarchical Clustering.
- 2) Menentukan jumlah cluster yang optimal melalui analisis visual dendrogram pada dataset Mall Customer Segmentation.
- 3) Menganalisis dan mendeskripsikan karakteristik (profil) setiap cluster pelanggan yang terbentuk sebagai dasar rekomendasi strategi pemasaran.

1.5. Manfaat Penelitian

Dari hasil penelitian ini, terdapat beberapa pihak yang diharapkan dapat memperoleh manfaat, antara lain sebagai berikut.

- 1) **Pihak Manajemen Mall/Retail:** Dapat memahami segmentasi pelanggan berdasarkan Annual Income dan Spending Score, sehingga dapat menyusun strategi promosi dan layanan yang lebih tepat sasaran untuk masing-masing segmen pelanggan.
- 2) **Tim Pemasaran (Marketing):** Hasil profiling cluster dapat dijadikan dasar penentuan target kampanye pemasaran, penawaran produk, maupun program loyalitas yang sesuai dengan karakteristik tiap segmen pelanggan.
- 3) **Akademisi/Peneliti Selanjutnya:** Penelitian ini dapat menjadi referensi dan pembanding bagi penelitian lain yang membahas penerapan Hierarchical Clustering pada data perilaku pelanggan, khususnya pada konteks industri ritel.

1.6. Metode Penelitian

Penelitian ini dilakukan melalui beberapa tahapan. Adapun metode yang digunakan dalam tiap-tiap tahapan antara lain sebagai berikut.

1) Metode Pengumpulan Data

Pengumpulan data dilakukan melalui wawancara, kuisioner, studi pustaka dan observasi lapangan.

2) Metode Analisis Data

Dataset (csv) dikelola menggunakan Bahasa pemrograman python/R dengan library dan metode tertentu.

3) Metode Pemodelan dan Validasi Data

1. Membangun skenario model

...

2. Membangun model

...

3. Mengevaluasi model

...

1.7. Sistematika Penulisan

Sistem penulisan dalam tugas akhir ini disusun dalam bentuk karya ilmiah dengan struktur penulisan sebagai berikut:

BAB 1 PENDAHULUAN

Bab ini berisi uraian tentang latar belakang masalah yang mendasari pentingnya diadakan penelitian, identifikasi, pembatasan dan perumusan masalah penelitian, maksud dan tujuan penelitian, kegunaan penelitian yang diharapkan, dan sistematika penulisan.

BAB 2 LANDASAN TEORI

Bab ini berisi tinjauan teori yang mendiskripsikan pengertian.... (hal-hal yang berhubungan dengan topik penelitian).

BAB 3 ANALISIS DAN PERANCANGAN SISTEM

Bab ini berisi tentang analisis kebutuhan dari sistem yang akan dibangun, perbandingan sistem yang sudah ada dengan sistem yang diusulkan, dan perancangan sistem yang diusulkan.

BAB 4 TESTING DAN IMPLEMENTASI

Bab ini berisi tentang penjelasan prosedur testing dan proses pengujian sistem yang telah dibuat.

BAB 5 PENUTUP

Bab ini berisi pokok-pokok kesimpulan dan saran-saran yang perlu disampaikan kepada pihak-pihak yang berkepentingan dengan hasil penelitian.

DAFTAR PUSTAKA

Daftar pustaka berisi daftar referensi yang digunakan dalam penelitian.

BAB 2 TINJAUAN PUSTAKA

Bab ini memaparkan penelitian-penelitian terdahulu yang berkaitan dengan topik penelitian, serta menjelaskan teori-teori yang menjadi landasan penulis dalam penyusunan tugas akhir ini.

2.1. Penelitian Terdahulu

Penelitian terdahulu disajikan untuk menunjukkan keaslian penelitian ini. Bagian ini memuat uraian sistematis mengenai hasil penelitian-penelitian sebelumnya yang relevan dengan topik segmentasi pelanggan menggunakan metode clustering, khususnya Hierarchical Clustering, sebagaimana dirangkum pada tabel berikut.

No	Penelitian Terdahulu	Kekurangan	Usulan
1	Ashwani, Kaur, & Rani (2023). Mall Customer Segmentation Using K-Means Clustering.	Menggunakan K-Means yang mengharuskan jumlah cluster (k) ditentukan di awal secara manual/uji coba, tanpa visualisasi struktur hierarki (dendrogram) yang dapat membantu penentuan jumlah cluster secara lebih objektif.	Penelitian ini menerapkan Agglomerative Hierarchical Clustering yang dilengkapi visualisasi dendrogram, sehingga jumlah cluster optimal dapat ditentukan berdasarkan struktur data, kemudian divalidasi lebih lanjut dengan Silhouette Score.
2	Rungruang, Riyapan, Intarasit, Chuarkham, & Muangprathub (2024). RFM Model Customer Segmentation Based on Hierarchical Approach Using FCA.	Menggunakan kombinasi model RFM (Recency, Frequency, Monetary) dengan Formal Concept Analysis (FCA) yang relatif kompleks dan	Penelitian ini menggunakan pendekatan Agglomerative Hierarchical Clustering konvensional pada dua atribut utama (Annual

		membutuhkan data transaksi historis yang detail, sehingga sulit direplikasi pada dataset sederhana yang hanya memuat atribut demografis dan skor belanja.	Income dan Spending Score) yang lebih sederhana, mudah diinterpretasikan, dan tetap relevan untuk konteks segmentasi pelanggan skala mall/ritel menengah.
3	Srivastava & Saxena (2025). Enhanced Customer: A Comparative Analysis of Leading Clustering Algorithms.	Membandingkan enam algoritma clustering pada dataset Mall Customer Segmentation, namun tidak menjelaskan secara rinci proses standarisasi/scaling fitur sebelum clustering, serta tidak melakukan profiling mendalam terhadap karakteristik tiap cluster untuk interpretasi bisnis.	Penelitian ini melakukan standarisasi fitur (StandardScaler) sebelum proses clustering serta melakukan profiling lengkap tiap cluster (rata-rata usia, Annual Income, dan Spending Score) sebagai dasar rekomendasi strategi pemasaran yang lebih konkret.

Berdasarkan tinjauan terhadap ketiga penelitian terdahulu tersebut, dapat disimpulkan bahwa metode Hierarchical Clustering memiliki keunggulan dalam aspek interpretabilitas dan fleksibilitas penentuan jumlah cluster dibandingkan K-Means (Ashwani, Kaur, & Rani, 2023), namun pendekatan yang lebih kompleks seperti kombinasi RFM dan Formal Concept Analysis (Rungruang, Riyapan, Intarasit, Chuarkham, & Muangprathub, 2024) maupun perbandingan multi-algoritma (Srivastava & Saxena, 2025) belum banyak disertai validasi kuantitatif berupa Silhouette Score maupun profiling karakteristik cluster secara mendalam. Oleh karena itu, penelitian ini diposisikan sebagai penyempurnaan dari pendekatan-pendekatan tersebut, dengan menggabungkan visualisasi dendrogram, validasi Silhouette Score, dan profiling cluster yang komprehensif pada dataset Mall Customer

Segmentation, sehingga hasil segmentasi yang diperoleh lebih mudah diinterpretasikan dan diterapkan dalam pengambilan keputusan pemasaran.

2.2. Landasan Teori

Bagian ini memuat rangkuman teori-teori yang menjadi dasar penulis dalam memahami dan menyelesaikan permasalahan penelitian, mencakup konsep segmentasi pelanggan, clustering, Hierarchical Clustering, beserta komponen dan tools pendukung yang digunakan.

2.2.1. Segmentasi Pelanggan (Customer Segmentation)

Segmentasi pelanggan (customer segmentation) merupakan proses membagi populasi pelanggan menjadi beberapa kelompok yang lebih kecil berdasarkan kemiripan karakteristik, seperti perilaku belanja, demografi, maupun kemampuan ekonomi. Tujuan dari segmentasi ini adalah agar perusahaan dapat memahami kebutuhan tiap kelompok pelanggan secara lebih spesifik, sehingga strategi pemasaran yang disusun menjadi lebih tepat sasaran dan efisien dibandingkan pendekatan pemasaran yang bersifat seragam untuk seluruh pelanggan (Rungruang, Riyapan, Intarasit, Chuarkham, & Muangprathub, 2024).

2.2.2. Unsupervised Learning dan Clustering

Clustering merupakan salah satu teknik dalam unsupervised learning, yaitu cabang pembelajaran mesin yang digunakan untuk menemukan pola atau struktur tersembunyi pada data tanpa memerlukan label target. Berbeda dengan supervised learning yang membutuhkan data berlabel untuk proses pelatihan model, clustering bekerja dengan mengelompokkan data berdasarkan tingkat kemiripan (similarity) antar titik data, sehingga data yang berada dalam satu cluster memiliki karakteristik yang relatif homogen, sedangkan data pada cluster yang berbeda memiliki karakteristik yang lebih heterogen (Abdulhafedh, 2021).

2.2.3. Hierarchical Clustering (Agglomerative)

Hierarchical Clustering adalah salah satu metode clustering yang membentuk struktur pengelompokan data secara bertingkat (hierarkis), tanpa perlu menentukan jumlah cluster di awal proses. Terdapat dua pendekatan dalam Hierarchical Clustering, yaitu agglomerative (bottom-up) dan divisive (top-down). Pendekatan agglomerative dimulai dengan memperlakukan setiap titik data sebagai cluster tersendiri, kemudian secara iteratif menggabungkan dua cluster yang memiliki jarak (dissimilarity) terkecil hingga seluruh data tergabung menjadi satu cluster besar.

Pendekatan ini lebih banyak digunakan dibandingkan divisive karena lebih sederhana secara komputasional (Abdulhafedh, 2021). Jarak antar titik data pada penelitian ini dihitung menggunakan Euclidean Distance, yang dirumuskan sebagai berikut.

$$d(x, y) = \sqrt{(\sum (x_i - y_i)^2)}, i = 1, 2, \dots, n$$

dengan $d(x, y)$ merupakan jarak Euclidean antara titik data x dan y , sedangkan x_i dan y_i adalah nilai atribut ke- i dari masing-masing titik data.

2.2.4. Metode Linkage (Wards Method)

Proses penggabungan cluster pada Hierarchical Clustering memerlukan suatu kriteria atau metode linkage untuk menentukan jarak antar cluster. Beberapa metode linkage yang umum digunakan antara lain single linkage, complete linkage, average linkage, dan ward linkage. Pada penelitian ini digunakan metode Ward Linkage (Ward's Minimum Variance Method), yang menggabungkan dua cluster berdasarkan kriteria peningkatan variansi (sum of squared error) yang paling minimum, sehingga cluster yang terbentuk cenderung lebih kompak dan seimbang dibandingkan metode linkage lainnya (Ward, 1963).

2.2.5. Dendrogram

Dendrogram merupakan representasi visual berbentuk diagram pohon yang menggambarkan proses penggabungan cluster secara bertahap pada Hierarchical Clustering. Sumbu horizontal pada dendrogram merepresentasikan setiap titik data atau cluster, sedangkan sumbu vertikal merepresentasikan jarak (dissimilarity) pada saat dua cluster digabungkan. Penentuan jumlah cluster optimal dapat dilakukan dengan menarik garis horizontal pada jarak vertikal terbesar yang belum terpotong oleh garis penggabungan manapun; jumlah garis vertikal yang terpotong oleh garis tersebut menunjukkan jumlah cluster yang disarankan (Abdulhafedh, 2021).

2.2.6. Standarsasi Data (feature Scaling)

Standardisasi data merupakan tahap praproses yang dilakukan untuk menyamakan skala antar fitur numerik sebelum proses clustering dilakukan. Hal ini penting karena algoritma Hierarchical Clustering menghitung jarak antar titik data menggunakan Euclidean Distance, sehingga fitur dengan rentang nilai yang lebih besar berpotensi mendominasi perhitungan jarak apabila tidak distandarisasi terlebih dahulu. Salah satu metode standardisasi yang umum digunakan adalah Z-score Standardization, yang dirumuskan sebagai berikut.

$$z = (x - \mu) / \sigma$$

dengan z adalah nilai data setelah standarisasi, x adalah nilai data asli, μ adalah rata-rata (mean) dari fitur, dan σ adalah standar deviasi dari fitur tersebut.

2.2.7. Silhouette Score

Silhouette Score merupakan salah satu metode evaluasi internal yang digunakan untuk mengukur kualitas hasil clustering, dengan membandingkan tingkat kemiripan suatu titik data terhadap cluster-nya sendiri (cohesion) dibandingkan dengan cluster lain yang terdekat (separation). Nilai Silhouette Score untuk satu titik data dirumuskan sebagai berikut.

$$s(i) = (b(i) - a(i)) / \max \{ a(i), b(i) \}$$

dengan $a(i)$ adalah rata-rata jarak titik data i terhadap seluruh titik data lain dalam cluster yang sama, dan $b(i)$ adalah rata-rata jarak terkecil titik data i terhadap titik-titik data pada cluster lain. Nilai Silhouette Score berkisar antara -1 hingga 1 ; semakin mendekati nilai 1 , semakin baik kualitas pengelompokan yang dihasilkan, karena menunjukkan bahwa titik data tersebut sudah berada pada cluster yang tepat dan terpisah dengan baik dari cluster lainnya (Rousseeuw, 1987).

2.2.8. Tools dan Library yang Digunakan

Implementasi Hierarchical Clustering pada penelitian ini dilakukan menggunakan bahasa pemrograman Python pada lingkungan Jupyter Notebook, dengan memanfaatkan beberapa library pendukung, yaitu Pandas dan NumPy untuk manipulasi dan eksplorasi data, Matplotlib dan Seaborn untuk visualisasi data, SciPy (modul `cluster.hierarchy`) untuk pembuatan dendrogram dan proses linkage, serta Scikit-learn untuk implementasi algoritma Agglomerative Clustering, standarisasi data melalui `StandardScaler`, dan perhitungan Silhouette Score.

BAB 3


METODOLOGI PENELITIAN

Bab ini menjelaskan tahapan metodologi yang digunakan dalam penelitian, dimulai dari kerangka berpikir, proses pengumpulan dan pengolahan data, hingga perancangan teknik Agglomerative Hierarchical Clustering yang diterapkan untuk menyelesaikan permasalahan segmentasi pelanggan mall.

3.1. Kerangka Berpikir

Kerangka berpikir penelitian ini disusun dalam bentuk diagram swimlane dengan kolom Input–Proses–Output untuk menggambarkan alur kerja secara sistematis. Kolom Input memuat sumber data dan parameter model yang digunakan. Kolom Proses mencakup seluruh tahapan analisis, mulai dari eksplorasi data hingga clustering. Kolom Output berisi hasil segmentasi dan rekomendasi yang dihasilkan dari proses tersebut.

Gambar 3.1 Kerangka Berpikir Penelitian (Swimlane)



Berdasarkan kerangka berpikir di atas, penelitian ini mengalir dari penerimaan dataset sebagai input, kemudian melewati lima tahap proses berurutan: (1) eksplorasi data awal untuk memahami distribusi dan pola data; (2) preprocessing berupa feature selection dan standarisasi menggunakan Z-score (StandardScaler); (3) pembuatan dendrogram untuk melihat struktur hierarki pengelompokan; (4) penentuan jumlah cluster optimal melalui Silhouette Score; dan (5) penerapan Agglomerative Clustering untuk menetapkan label cluster

setiap pelanggan. Keluaran akhir berupa profiling lima segmen pelanggan beserta rekomendasi strategi pemasaran yang sesuai dengan karakteristik masing-masing segmen.


3.2. Pengumpulan dan Pengolahan Data

Tahapan pengumpulan dan pengolahan data pada penelitian ini dijelaskan secara rinci dalam dua sub-bagian berikut.

3.2.1. Pengumpulan Data

Data yang digunakan dalam penelitian ini merupakan data sekunder berupa dataset publik Mall Customer Segmentation Data yang bersumber dari platform Kaggle. Dataset ini tidak memerlukan kegiatan survei atau pengumpulan lapangan, karena tersedia secara terbuka untuk keperluan penelitian dan pembelajaran. Proses pengumpulan data dilakukan melalui tahapan sebagaimana digambarkan pada flowchart berikut.

Gambar 3.2 Flowchart Pengumpulan Data



Dataset yang diperoleh berformat CSV dengan nama `Mall_Customers.csv`. Setelah proses load menggunakan fungsi `pd.read_csv()` pada Python, dilakukan verifikasi terhadap kelengkapan dan kualitas data. Hasil verifikasi menunjukkan bahwa dataset terdiri dari 200 baris dan 5 kolom (CustomerID, Gender, Age, Annual Income, Spending Score), tidak ditemukan missing value pada seluruh kolom, serta tidak terdapat data duplikat. Dengan demikian, dataset dinyatakan valid dan siap untuk digunakan pada tahap pengolahan data.

3.2.2. Pengolahan Data

Jelaskan proses pengolahan data yang dilakukan setelah data dikumpulkan. Bagian ini mencakup metode dan teknik yang digunakan untuk mengolah data, seperti pembersihan data, pengkodean, analisis statistik, atau teknik lain yang relevan. Diagram pendukung dapat digunakan untuk memperjelas proses pengolahan data. Setelah dataset dinyatakan valid, dilakukan beberapa tahap pengolahan data sebelum proses clustering dimulai. Tahapan pengolahan data terdiri dari dua proses utama, yaitu feature selection dan feature scaling.

1) Feature Selection

Dari lima atribut yang tersedia pada dataset (CustomerID, Gender, Age, Annual Income, Spending Score), hanya dua atribut numerik yang dipilih sebagai fitur clustering, yaitu Annual Income (k\$) dan Spending Score (1-100). Kedua atribut ini dipilih karena secara langsung merepresentasikan kemampuan ekonomi dan kecenderungan belanja pelanggan, serta menghasilkan pola pengelompokan yang paling representatif secara visual (Ashwani, Kaur, & Rani, 2023). Proses feature selection dilakukan dengan kode berikut.

```
X = df[["Annual Income (k$)", "Spending Score (1-100)"]].values
```

2) Feature Scaling (Standardisasi)

Karena algoritma Hierarchical Clustering menggunakan Euclidean Distance dalam menghitung kemiripan antar data, fitur-fitur yang memiliki rentang nilai berbeda perlu distandarisasi terlebih dahulu agar tidak ada fitur yang mendominasi perhitungan jarak. Pada penelitian ini digunakan metode Z-score Standardization melalui kelas `StandardScaler` dari library Scikit-learn, seperti berikut.


```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

Setelah standardisasi, setiap fitur memiliki nilai rata-rata 0 dan standar deviasi 1. Sebagai contoh, data pertama yang semula bernilai Annual Income = 15 dan Spending Score = 39, setelah scaling berubah menjadi masing-masing -1.739 dan -0.435 , menunjukkan bahwa data tersebut berada di bawah rata-rata untuk kedua fitur.

3.3. Perancangan Teknik/Model (*Kebaharuan*)

Perancangan model pada penelitian ini menggunakan metode Agglomerative Hierarchical Clustering dengan metode linkage Ward sebagai teknik pengelompokan utama. Tahapan perancangan model secara lengkap digambarkan pada flowchart berikut.

Gambar 3.3 Flowchart Perancangan Model Agglomerative Hierarchical Clustering



Berdasarkan flowchart di atas, perancangan model terdiri dari lima tahap utama. Pertama, data hasil preprocessing (X_{scaled}) dijadikan input. Kedua, dihitung linkage matrix Z menggunakan metode Ward ($linkage(X_{scaled}, method='ward')$), yang merupakan representasi matematis dari semua kemungkinan penggabungan cluster beserta jaraknya. Ketiga, visualisasi dendrogram dihasilkan dari linkage matrix Z untuk membantu mengidentifikasi kandidat jumlah cluster secara visual, dengan menambahkan garis pemotongan horizontal pada jarak = 6, sehingga terlihat adanya 5 kelompok yang terpisah dengan jelas.

Keempat, dilakukan validasi kuantitatif dengan menghitung Silhouette Score untuk setiap nilai k dari 2 hingga 10. Hasil perhitungan menunjukkan bahwa nilai $k = 5$ menghasilkan Silhouette Score tertinggi sebesar 0.5538, yang mengkonfirmasi bahwa 5 cluster adalah jumlah yang paling optimal untuk dataset ini. Kelima, algoritma AgglomerativeClustering dijalankan dengan parameter $n_clusters = 5$ dan $linkage = 'ward'$ untuk menetapkan label cluster (0–4) pada setiap pelanggan. Hasil penetapan label ini kemudian digunakan sebagai dasar tahap profiling cluster pada BAB 4.

Tabel 3.1 Parameter model Agglomerative Hierarchical Clustering

Parameter	Nilai	Keterangan
Algoritma	Agglomerative Clustering	Hierarchical bottom-up approach
Metode Linkage	Ward	Meminimalkan variansi dalam cluster
Metode Jarak	Euclidean Distance	Jarak geometris antar titik data
Fitur yang Digunakan	Annual Income (k\$), Spending Score (1-100)	2 atribut numerik utama dari dataset
Preprocessing	StandardScaler (Z-score)	Standardisasi skala antar fitur
Jumlah Cluster (k)	5	Ditentukan dari dendrogram + Silhouette Score tertinggi (0.5538)
Evaluasi Model	Silhouette Score	Mengukur cohesion & separation cluster (Rousseeuw, 1987)
Implementasi	Python (Scikit-learn, SciPy)	Jupyter Notebook environment

3.4. Evaluasi Teknik/Model (*Teknik Evaluasi*)

Bagian ini menjelaskan teknik evaluasi yang digunakan untuk menilai kinerja dan efektivitas model yang diusulkan. Teknik evaluasi dapat mencakup metode pengujian, metrik evaluasi, dan prosedur yang digunakan untuk mengukur keberhasilan model. Penjelasan ini penting untuk memastikan bahwa model yang diusulkan dapat diandalkan dan memberikan hasil yang sesuai dengan tujuan penelitian. Diagram dan tabel dapat digunakan untuk memperjelas hasil evaluasi teknik/model.

BAB 4

IMPLEMENTASI DAN EKSPERIMEN

Pada bab ini akan dijelaskan hasil-hasil implementasi dan eksperimen yang telah dilakukan. Penelitian ini menerapkan Agglomerative Hierarchical Clustering pada dataset Mall Customer Segmentation untuk mengelompokkan pelanggan berdasarkan pendapatan tahunan (Annual Income) dan skor belanja (Spending Score). Seluruh proses diimplementasikan menggunakan bahasa pemrograman Python di lingkungan Jupyter Notebook dengan bantuan library NumPy, Pandas, Matplotlib, Seaborn, SciPy, dan Scikit-learn. Hasil yang diperoleh kemudian dibandingkan dengan penelitian terdahulu untuk menunjukkan keunggulan dan validitas teknik yang diusulkan.

4.1. Persiapan Data

Bagian ini menjelaskan tahap persiapan data yang diperlukan untuk implementasi dan eksperimen. Persiapan data meliputi pengumpulan dan pengolahan data yang akan digunakan dalam penelitian.

4.1.1. Pengumpulan Data

Data yang digunakan dalam penelitian ini adalah dataset publik Mall Customer Segmentation Data yang diunduh dari platform Kaggle. Dataset ini terdiri dari 200 baris data pelanggan dengan lima atribut, yaitu:

- CustomerID : identitas unik pelanggan (integer)
- Gender : jenis kelamin (Male/Female)
- Age : usia pelanggan (tahun)
- Annual Income (k\$) : pendapatan tahunan dalam ribuan dolar
- Spending Score (1-100) : skor perilaku belanja (1 = sangat rendah, 100 = sangat tinggi)

Data diimpor menggunakan fungsi `pd.read_csv()` dan diverifikasi kelengkapannya. Hasil pemeriksaan menunjukkan bahwa dataset tidak memiliki nilai hilang (missing value) maupun data duplikat, sehingga dinyatakan layak untuk digunakan pada tahap selanjutnya..

4.1.2. Pengolahan Data

Pengolahan data dilakukan melalui dua tahap utama:

1. Feature Selection

Dari lima atribut yang tersedia, hanya dua fitur numerik yang digunakan dalam proses clustering, yaitu:

- Annual Income (k\$)
- Spending Score (1-100)

Pemilihan ini didasarkan pada penelitian sebelumnya (Ashwani, Kaur, & Rani, 2023) yang menunjukkan bahwa kedua variabel tersebut paling dominan dalam membentuk pola segmentasi pelanggan. Atribut Gender dan Age tidak digunakan dalam pembentukan cluster, namun tetap dipertahankan untuk analisis profil tambahan pada tahap profiling.

2. Feature Scaling (Standardisasi)

Karena algoritma hierarchical clustering menggunakan Euclidean distance untuk mengukur kemiripan antar titik data, fitur dengan rentang nilai yang berbeda perlu distandarisasi agar tidak ada fitur yang mendominasi. Metode Z-score standardization (StandardScaler) diterapkan sehingga setiap fitur memiliki rata-rata 0 dan simpangan baku 1.

```
x = df[["Annual Income (k$)", "Spending Score (1-100)"]].values

scaler = StandardScaler()
x_scaled = scaler.fit_transform(x)

print("Contoh data sebelum scaling:\n", x[:5])
print("\nContoh data setelah scaling:\n", x_scaled[:5])
```

Contoh data sebelum scaling:

```
[[15 39]
 [15 81]
 [16  6]
 [16 77]
 [17 40]]
```

Contoh data setelah scaling:

```
[[-1.73899919 -0.43480148]
 [-1.73899919  1.19570407]
 [-1.70082976 -1.71591298]
 [-1.70082976  1.04041783]
```

[-1.66266033 -0.39597992]] , Contoh hasil standardisasi untuk data pertama: Annual Income = 15 dan Spending Score = 39 berubah menjadi -1.739 dan -0.435, menunjukkan bahwa kedua nilai tersebut berada di bawah rata-rata.

4.2. Implementasi Teknik/Model

Bagian ini menjelaskan implementasi teknik atau model yang diusulkan dalam penelitian. Implementasi dilakukan untuk menguji kinerja dan efektivitas model yang telah dirancang.

4.2.1. Agglomerative Hierarchical Clustering

Penjelasan mencakup langkah-langkah implementasi, alat dan teknologi yang digunakan, serta parameter atau konfigurasi yang diterapkan. Sertakan diagram atau ilustrasi yang dapat membantu dalam memahami implementasi teknik model ini. Model *clustering* yang digunakan adalah **Agglomerative Hierarchical Clustering** dengan metode *linkage Ward* (Ward's minimum variance method). Metode ini meminimalkan peningkatan variansi (*sum of squared error*) pada setiap penggabungan *cluster*, sehingga menghasilkan *cluster* yang lebih kompak dan seimbang.

Langkah langkah implementasi adalah sebagai berikut:

1. Pembuatan Dedrogram

Dendrogram dibangun menggunakan fungsi *linkage* dari modul `scipy.cluster.hierarchy` untuk memvisualisasikan proses penggabungan *cluster* secara bertahap. Garis potong horizontal (pada jarak 6) menunjukkan adanya lima kelompok yang terpisah dengan jelas.

2. Penentuan Jumlah Cluster Optimal

Untuk memastikan jumlah *cluster* yang tepat, dilakukan validasi kuantitatif dengan **Silhouette Score** untuk nilai k dari 2 hingga 10. Hasil perhitungan adalah sebagai berikut:

k	Silhouette Score
2	0.3842
3	0.4610
4	0.4926
5	0.5538
6	0.5387
7	0.5198
8	0.4309
9	0.4377
10	0.4339

Nilai tertinggi dicapai pada $k = 5$, yang mengonfirmasi bahwa lima *cluster* adalah jumlah yang paling optimal untuk dataset ini.

3. Penerapan model

Dengan parameter `n_clusters = 5` dan `linkage = 'ward'`, model `AgglomerativeClustering` dari Scikit-learn diterapkan pada data yang telah diskalakan. Setiap pelanggan diberi label *cluster* (0–4).


```

n_clusters = 5

hc = AgglomerativeClustering(n_clusters=n_clusters, linkage="ward")
df["Cluster"] = hc.fit_predict(X_scaled)

print("Jumlah anggota tiap cluster:")
print(df["Cluster"].value_counts().sort_index())
df.head()

```

Gambar 4.1 Visualisasi Hasil Clustering

Jumlah anggota tiap cluster:

Cluster

0 : 32

1 : 39

2 : 85

3 : 21

0	CustomerID	Gender	Age	Annual Income (k\$)	Spending Score (1-100)	Cluster
0	1	Male	19	15	39	4
1	2	Male	21	15	81	3
2	3	Female	20	16	6	4
3	4	Female	23	16	77	3

Table 4.1 Clusturingng

4.2.2. Visualisasi Hasil Clustering

Hasil clustering divisualisasikan dalam scatter plot dua dimensi dengan sumbu Annual Income dan Spending Score. Setiap titik diwarnai sesuai dengan label cluster yang diberikan.

Gambar 4.1 menampilkan sebaran pelanggan dalam lima cluster yang terbentuk. Terlihat bahwa cluster-cluster tersebut terpisah dengan cukup baik, terutama untuk kelompok dengan pendapatan tinggi dan skor belanja tinggi (Cluster 1) serta kelompok dengan pendapatan rendah dan skor belanja rendah (Cluster 4). Hal ini menunjukkan bahwa metode Agglomerative Hierarchical Clustering berhasil menangkap pola segmentasi yang alami dalam data.

4.3. Hasil dan Analisis

Bagian ini menjelaskan hasil dari implementasi dan eksperimen yang dilakukan. Analisis hasil dilakukan untuk mengevaluasi kinerja model yang diusulkan dan membandingkannya dengan model atau metode sebelumnya.

4.3.1. Interpretasi Kinerja Model

Kualitas *clustering* dievaluasi menggunakan **Silhouette Score** yang telah dihitung sebelumnya. Nilai 0.5538 untuk $k = 5$ menunjukkan bahwa rata-rata kohesi dalam *cluster* cukup tinggi dan pemisahan antar *cluster* cukup baik. Meskipun belum mencapai nilai di atas 0,6, skor ini masih tergolong “cukup baik” (Rousseeuw, 1987) dan lebih tinggi dibandingkan dengan nilai untuk k lainnya, sehingga model yang dihasilkan dapat diandalkan untuk keperluan segmentasi.

Selain itu, visualisasi dendrogram memberikan gambaran hierarki pengelompokan yang memudahkan interpretasi dan memungkinkan pengambil keputusan untuk menentukan jumlah cluster secara fleksibel sesuai kebutuhan bisnis.

4.3.2. Evaluasi Kinerja Model

Untuk menunjukkan keunggulan metode yang diusulkan, hasil ini dibandingkan dengan penelitian terdahulu yang menggunakan K-Means *clustering* (Ashwani, Kaur, & Rani, 2023) dan pendekatan RFM dengan Formal Concept Analysis (Rungruang dkk., 2024). Beberapa poin perbandingan:

- **K-Means** memerlukan penetapan jumlah *cluster* secara manual dan tidak menyediakan struktur hierarki. Penelitian ini menggunakan *dendrogram* yang membantu penentuan jumlah *cluster* secara lebih objektif.
- Pendekatan RFM-FCA lebih kompleks dan membutuhkan data transaksi historis yang detail, sedangkan penelitian ini hanya menggunakan dua atribut utama (*Annual Income* dan *Spending Score*) sehingga lebih sederhana dan mudah diinterpretasikan.
- Penelitian ini juga menyertakan validasi kuantitatif melalui *Silhouette Score* serta *profiling* karakteristik tiap *cluster*, yang tidak dilakukan secara mendalam pada penelitian pembandingan.

Dengan demikian, pendekatan Agglomerative Hierarchical Clustering yang dilengkapi dengan *dendrogram*, validasi *silhouette*, dan *profiling* komprehensif memberikan hasil segmentasi yang lebih informatif dan aplikatif untuk strategi pemasaran.

4.3.3. Pembahasan Temuan

Profil Cluster

Rata-rata (mean) usia, pendapatan tahunan, dan skor belanja untuk setiap cluster disajikan dalam Tabel 4.1.

Cluster	Age	Annual Income (k\$)	Spending Score (1-100)	Jumlah Pelanggan
0	41.0	89.4	15.6	32
1	32.7	86.5	82.1	39
2	42.5	55.8	49.1	85
3	25.3	25.1	80.0	21

Table 4.2 Bloxplot Distribusi

- Cluster 0 (Income Tinggi – Skor Rendah) : Pelanggan dengan pendapatan tinggi tetapi skor belanja sangat rendah. Kelompok ini cenderung hemat atau konservatif dalam berbelanja. Strategi pemasaran yang tepat adalah memberikan insentif berupa program loyalitas atau penawaran eksklusif untuk mendorong pengeluaran.
- Cluster 1 (Income Tinggi – Skor Tinggi) : Pelanggan premium dengan pendapatan dan skor belanja tinggi. Kelompok ini merupakan target utama untuk produk premium, *upselling*, dan program *membership*.
- Cluster 2 (Income & Skor Sedang) : Pelanggan dengan pendapatan dan skor belanja rata-rata. Ini adalah segmen terbesar (85 pelanggan) dan mewakili pelanggan umum. Strategi promosi massal dan paket bundling dapat efektif untuk kelompok ini.
- Cluster 3 (Income Rendah – Skor Tinggi) : Pelanggan berpendapatan rendah tetapi memiliki skor belanja tinggi. Kelompok ini cenderung impulsif dan responsif terhadap diskon atau promosi. Pemasaran yang menekankan nilai dan potongan harga akan menarik perhatian mereka.
- Cluster 4 (Income Rendah – Skor Rendah) : Pelanggan dengan pendapatan dan skor belanja rendah. Kelompok ini pasif dan mungkin memerlukan strategi *re-engagement* atau edukasi tentang produk agar lebih aktif.

Keterbatasan Penelitian

Penelitian ini hanya menggunakan dua fitur utama dan tidak mempertimbangkan aspek temporal seperti frekuensi kunjungan atau nilai transaksi historis. Selain itu, data yang digunakan bersifat statis dan tidak mencerminkan perubahan perilaku pelanggan dari waktu ke waktu. Penelitian lanjutan dapat memperkaya fitur dengan data RFM (Recency, Frequency, Monetary) atau menggunakan pendekatan clustering lain seperti DBSCAN untuk mengatasi outlier.

4.3.4. Hasil Akhir

Secara keseluruhan, penerapan Agglomerative Hierarchical Clustering pada dataset *Mall Customer Segmentation* berhasil menghasilkan lima segmen pelanggan yang berbeda karakteristiknya. Hasil ini dapat langsung digunakan oleh tim pemasaran untuk merancang kampanye promosi yang lebih efektif dan efisien. Dengan adanya *dendrogram* dan validasi *Silhouette Score*, penelitian ini juga memberikan dasar yang kuat dalam menentukan jumlah *cluster* yang optimal.

BAB 5

PENUTUP

5.1. Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa:

1. Pola pengelompokan pelanggan mall berhasil diidentifikasi menggunakan metode Agglomerative Hierarchical Clustering dengan fitur Annual Income dan Spending Score. Terbentuk lima cluster yang masing-masing memiliki karakteristik berbeda, mulai dari pelanggan premium hingga pelanggan pasif.
2. Jumlah cluster optimal yang ditentukan melalui visualisasi dendrogram dan validasi Silhouette Score adalah $k = 5$, dengan nilai Silhouette Score tertinggi sebesar 0.5538. Hal ini menegaskan bahwa data pelanggan dapat dikelompokkan secara alami ke dalam lima segmen yang bermakna.
3. Profil masing-masing cluster menunjukkan perbedaan yang jelas dalam hal pendapatan dan skor belanja, sehingga rekomendasi strategi pemasaran dapat disusun secara spesifik untuk setiap segmen. Misalnya, cluster dengan pendapatan tinggi dan skor belanja tinggi (Cluster 1) layak mendapatkan program loyalitas premium, sedangkan cluster dengan pendapatan rendah dan skor belanja tinggi (Cluster 3) lebih responsif terhadap promosi harga.

Dengan demikian, metode yang diusulkan layak digunakan sebagai alat bantu pengambilan keputusan dalam manajemen hubungan pelanggan (*Customer Relationship Management*) di industri ritel.

5.2. Saran

Penelitian selanjutnya disarankan untuk menambahkan fitur-fitur lain seperti Age, Gender, atau data transaksi (RFM) agar segmentasi lebih komprehensif dan dapat menangkap perilaku belanja secara lebih detail.

Perlu dilakukan uji coba dengan algoritma clustering lain, seperti K-Means atau DBSCAN, dan membandingkan hasilnya untuk melihat metode mana yang paling sesuai dengan karakteristik data.

Implementasi model ke dalam sistem aplikasi berbasis dashboard dapat membantu tim pemasaran memantau segmentasi pelanggan secara real-time dan menyesuaikan strategi promosi secara dinamis.

DAFTAR PUSTAKA

- Penulisan Abdulhafedh, A. (2021). *Incorporating K-means, hierarchical clustering and PCA in customer segmentation*. *Journal of City and Development*, 3(1), 12–30. <https://doi.org/10.12691/jcd-3-1-3>. Tersedia pada: <http://pubs.sciepub.com/jcd/3/1/3/index.html>
- Ashwani, Kaur, G., & Rani, L. (2023). *Mall customer segmentation using K-Means clustering*. *Dalam Proceedings of Data Analytics and Management (ICDAM 2023), Lecture Notes in Networks and Systems*, vol. 788 (hlm. 459–474). Springer, Singapore. https://doi.org/10.1007/978-981-99-6553-3_35. Tersedia pada: https://link.springer.com/chapter/10.1007/978-981-99-6553-3_35
- Rungruang, C., Riyapan, P., Intarasit, A., Chuarkham, K., & Muangprathub, J. (2024). *RFM model customer segmentation based on hierarchical approach using FCA*. *Expert Systems with Applications*, 237, 121449. <https://doi.org/10.1016/j.eswa.2023.121449>. Tersedia pada: <https://www.sciencedirect.com/science/article/abs/pii/S0957417423019516>
- Srivastava, P., & Saxena, D. S. (2025). Enhanced customer: A comparative analysis of leading clustering algorithms. *International Journal of Novel Research and Development*, 10(4), a258–a262. Tersedia pada: <https://ijnrd.org/papers/IJNRD2504030.pdf>
- Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, 58(301), 236–244. <https://doi.org/10.1080/01621459.1963.10500845>. Tersedia pada: <https://doi.org/10.1080/01621459.1963.10500845>
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- Kurniawan, R., & Hidayat, T. (2022). Customer segmentation using hierarchical clustering in retail industry. *Jurnal Ilmiah Teknik Informatika*, 10(2), 112–120. (Referensi tambahan, 2022)
- Santoso, B., & Nugroho, A. (2023). Comparison of K-Means and hierarchical clustering for customer segmentation in e-commerce. *International Journal of Data Science*, 8(1), 45–55. (Referensi tambahan, 2023)
- Putri, D. A., & Suryani, E. (2024). Penerapan metode Agglomerative Hierarchical Clustering untuk segmentasi pelanggan pada pusat perbelanjaan. *Jurnal Sistem Informasi*, 16(1), 78–87. (Referensi tambahan, 2024)

Lee, C., & Kim, J. (2021). A study on customer segmentation using hierarchical clustering with RFM model. *Journal of Business Analytics*, 5(2), 99–110. (Referensi tambahan, 2021)